

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: Analiza opinii o restauracjach McDonald's z wykorzystaniem: zliczania częstości słów (TF-IDF), topic modelingu (LDA), oraz analizy sentymentu.

Data: 7.06.2026

Autorzy: Aleksander Mróz, Piotr Podobiński

1. Wprowadzenie:

Niniejszy dokument opisuje specyfikację wymagań dla skryptu R, który ma zadania umożliwić analizę opinii na temat restauracji McDonald's. Zrozumienie opinii, zwłaszcza negatywnych jest kluczowe dla poprawy funkcjonowania biznesu i doświadczenia klientów. Dodatkowo, współcześnie ważne jest żeby móc wykrywać review bombing czyli masowe wystawianie złych opinii (nie związanych bezpośrednio z funkcjonowaniem konkretnej restauracji) w ramach protestu spowodowanego na przykład kryzysem wizerunkowym. Wykrywanie review bombingu jest istotne dla identyfikowania problemów wizerunkowych marki oraz ustalenia czy recenzje są wiarygodnym feedbackiem klientów na temat funkcjonowania biznesu. Skrypt przetwarza dane tekstowe z pliku CSV, czyści tekst oraz wykorzystuje zliczanie częstości słów (TF-IDF), topic modeling (LDA), oraz analizę sentymentu. Skrypt umożliwia tworzenie raportów oraz graficznych przedstawień analizy w postaci wykresów i chmur słów.

2. Cele systemu:

- Wczytywanie danych (opinii) z pliku CSV.
- Czyszczenie tekstu
- Zliczanie częstości słów wykorzystując TF-IDF i wizualizacja danych w postaci chmury słów
- Przeprowadzenie analizy topic modeling (LDA) oraz wizualizacja w postaci wykresu
- Analiza sentymentu za pomocą słownika "Loughran" poprzedzona stemmingiem oraz wizualizacja w postaci wykresu

3. Wymagania funkcjonalne:

- **Wczytywanie danych:**
 - Skrypt powinien umożliwiać wczytywanie danych tekstowych z lokalnego pliku CSV.
 - Skrypt powinien obsługiwać kodowanie UTF-8
- **Przetwarzanie i oczyszczanie tekstu:**
 - Skrypt powinien umożliwiać normalizację apostrofów na apostrof klasyczny.
 - Skrypt powinien umożliwiać usunięcie liczb, interpunkcji oraz form skróconych zawierających apostrofy.
 - Skrypt powinien umożliwiać usunięcie pustych elementów oraz zbędnych znaków specjalnych.
 - Skrypt powinien umożliwiać usunięcie stopwords z pakietów tidytext i tm.
 - Skrypt powinien umożliwiać wykonanie stemmingu i uzupełnienia rdzeni słów.
- **Analiza częstości(TF-IDF):**
 - Skrypt powinien umożliwiać budowę macierzy Term-Document Matrix z ważeniem TF-IDF.
 - Skrypt powinien umożliwiać sortowanie słów według malejącej wartości TF-IDF.
 - Skrypt powinien umożliwiać ograniczenie słownika do najczęstszych słów w celu optymalizacji przetwarzania.
- **Analiza sentymentu:**
 - Skrypt powinien umożliwiać lematyzację słów przed przypisaniem sentymentu.
 - Skrypt powinien umożliwiać przypisanie sentymentu przy użyciu słownika Loughran.
 - Skrypt powinien umożliwiać filtrowanie wyników do kategorii pozytywnych i negatywnych.
 - Skrypt powinien umożliwiać zliczanie słów per kategoria sentymentu oraz wybór najczęstszych.
- **Topic modeling:**
 - Skrypt powinien umożliwiać budowę modelu LDA dla zadanej liczby tematów k.
 - Skrypt powinien umożliwiać ekstrakcję najważniejszych słów dla każdego tematu na podstawie wartości β .
- **Wizualizacja danych:**
 - Skrypt powinien umożliwiać generowanie wykresu słupkowego częstości słów (TF-IDF).
 - Skrypt powinien umożliwiać generowanie chmury słów z kolorowym kodowaniem częstości.

- Skrypt powinien umożliwiać generowanie wykresu słupkowego słów per kategoria sentymentu z podziałem na pozytywne i negatywne.
- Skrypt powinien umożliwiać generowanie wykresów rozkładu słów dla poszczególnych tematów LDA.

4. Wymagania нефункционалне:

- **Wydajność:**
 - Analiza pliku z recenzjami nie powinna trwać dłużej niż 45 sekund.
- **Безпеченство:**
 - System powinien zapewniać bezpieczeństwo danych wejściowych.
 - Do pełnego działania skryptu (po zainstalowaniu wymaganych bibliotek R) nie powinno być wymagane połączenie z Internetem.
- **Незаводность:**
 - Idempotentność: Wielokrotne uruchomienie skryptu z tym samym plikiem wejściowym CSV musi zawsze generować identyczne wyniki analizy (wyniki TF-IDF, wykresy i chmury słów). W przypadku algorytmu LDA (Topic Modeling) wymagane jest ustawienie stałego ziarna generatora liczb losowych.
- **Ужyteczność:**
 - Wykresy i wizualizacje powinny być czytelne.
- **Kompatybilność:**
 - Skrypt musi poprawnie działać na środowisku R w wersji 4.0 lub nowszej oraz być kompatybilny z systemami operacyjnymi Windows, macOS oraz Linux.

5. Interfejsy użytkownika:

- **Wejście:**
 - Plik w formacie CSV.
- **Wyjście:**
 - Wykres słupkowy 10 najczęstszych słów per kategoria sentymentu (pozytywna/negatywna) według słownika Loughran.
 - Wykresy słupkowe rozkładu słów dla poszczególnych tematów modelu LDA (domyślnie 3 tematy).
 - Wykres słupkowy 10 najważniejszych słów według sumarycznego wyniku TF-IDF.
 - Chmura słów (wordcloud) z kolorowym kodowaniem opartym na palecie Dark2.

- Tabela z wartościami TF-IDF posortowana malejąco według częstości występowania słów.

6. Wymagania dotyczące danych:

- Skrypt zakłada, że dane tekstowe są w języku angielskim.

7. Słownictwo dokumentacji:

- Stopwords: słowa niewnoszące wartości semantycznej do analizy (np. "the", "just", "got"), usuwane przy użyciu pakietów `tm` i `tidytext`.
- Korpus: zbiór przetworzonych dokumentów tekstowych (recenzji) reprezentowany przez obiekt `VCorpus`.
- Sentyment: emocjonalne nastawienie wyrażone w recenzji (pozytywne lub negatywne).
- Słownik sentymentów: lista słów i ich ocen wg sentymentu; w skrypcie wykorzystywany słownik Loughran.
- TF-IDF: miara ważności słowa w dokumencie względem całego zbioru; im wyższa wartość, tym bardziej charakterystyczne słowo.
- Lematyzacja: sprowadzenie słowa do jego formy podstawowej (lemat), realizowane funkcją `lemmatize_words` z pakietu `textstem`.
- Stem: forma słowa po sprowadzeniu go do rdzenia.
- LDA (Latent Dirichlet Allocation): probabilistyczny model topic modelingu grupujący słowa w tematy na podstawie współwystępowania.
- Beta (β): wartość określająca prawdopodobieństwo przynależności słowa do danego tematu w modelu LDA.
- Topic modeling: metoda ekstrakcji ukrytych tematów z kolekcji tekstów.
- Chmura słów: wizualizacja częstości słów, w której rozmiar słowa odpowiada jego wadze TF-IDF.

Przypadki użycia (use cases)

- Użytkownik:
 - wczytuje plik CSV.
 - uruchamia skrypt
 - wyświetla wyniki
 - generuje raport html oraz wykresy
- Skrypt:

- przetwarza tekst recenzji do korpusu
- oczyszcza tekst (usuwa znaki specjalne, liczby, interpunkcję, stopwords)
- oblicza wartości TF-IDF i sortuje słowa według częstości
- generuje chmurę słów
- generuje wykres słupkowy najważniejszych słów wg TF-IDF
- analizuje sentyment tekstu przy użyciu słownika Loughran
- generuje wykres porównujący słowa pozytywne i negatywne
- generuje wykresy rozkładu słów dla tematów modelu LDA

Scenariusze użytkownika (user stories)

Scenariusz 1: Wychwytywanie powodów negatywnych opinii

- **Jako:** Customer Experience (CX) Manager
- **Chcę:** Przeanalizować negatywne opinie o restauracjach.
- **Aby:** Zrozumieć z czego biorą się najbardziej negatywne opinie w celu poprawy doświadczenia klientów.

Kryteria akceptacji:

- Użytkownik może wczytać plik CSV. z opiniami klientów.
- Skrypt przeprowadza analizę częstości (TF-IDF), analizę sentymentu i topic modeling (LDA).
- Skrypt generuje wykresy i wizualizacje.
- Dzięki analizie topiców i częstości słów użytkownik jest w stanie zlokalizować obszary działalności wymagające poprawy.

Scenariusz 2: Wykrywanie review bombing

- **Jako:** Analityk marketingowy
- **Chcę:** Zweryfikować czy negatywne oceny nie są wynikiem review bombing.
- **Aby:** Kontrolować czy negatywne oceny są feedbackiem dotyczącym doświadczenia klienta w restauracji, czy też sprzeciwu konsumentów spowodowanym na przykład kryzysem wizerunkowym.

Kryteria akceptacji:

- Użytkownik może wczytać plik CSV. z opiniami klientów.
- Skrypt przeprowadza analizę częstości (TF-IDF), analizę sentymentu i topic modeling (LDA).
- Skrypt generuje wykresy i wizualizacje.
- Użytkownik może zobaczyć czy słowa o negatywnym sentymencie mają związek z funkcjonowaniem restauracji czy też są oznaką protestu.